

APLICAÇÃO DE DATA MINING PARA IDENTIFICAÇÃO DE RAÇAS DE CACHORROS

DIANE S. REIS¹, ELENINHA A. SANTOS², BRUNO F. L. SOUSA³, VITOR F. PEREIRA⁴, GABRIEL S. EZEQUIEL⁵

Faculdade Impacta de Tecnologia
São Paulo, São Paulo, Brasil
2023

RESUMO

Este artigo aborda a aplicação de técnicas de *Data Mining* e aprendizado profundo para a identificação de raças de cachorros com base em imagens. Diante do crescimento do mercado de animais de estimação, a identificação precisa de raças caninas torna-se crucial para orientar futuros proprietários na seleção responsável de seus animais de estimação. O estudo utiliza uma base de dados diversificada, composta por mais de 5.000 imagens que representam 20 raças de cães, abrangendo uma ampla variedade de cenários. Os resultados da avaliação de desempenho revelam uma acurácia de 80% de acerto para a identificação de algumas raças selecionadas. Este estudo contribui com *insights* valiosos sobre as limitações do modelo, ressaltando a necessidade contínua de avanços em técnicas de aprendizado de máquina para enfrentar desafios associados à classificação de raças de cães em grandes conjuntos de dados heterogêneos.

ABSTRACT

This article explores the application of data mining and deep learning techniques to predict dog breeds based on images. With the expanding pet market, precise identification of dog breeds becomes crucial in guiding prospective owners toward responsibly choosing their pets. The study utilized a diverse database, comprising over 5,000 images representing 20 dog breeds across a broad range of scenarios. The results of the performance evaluation reveal an accuracy of 80% for the identification of some selected breeds. This study provides valuable insights into the limitations of the model, emphasizing the ongoing need for advancements in machine learning techniques to tackle challenges associated with classifying dog breeds in large, heterogeneous datasets.

¹ Graduando em Banco de Dados pela Faculdade Impacta. Email: diane.reis@aluno.faculdadeimpacta.com.br

² Graduando em Banco de Dados pela Faculdade Impacta. Email: eleninha.santos@aluno.faculdadeimpacta.com.br

³ Graduando em Banco de Dados pela Faculdade Impacta. Email: bruno.sousa@aluno.faculdadeimpacta.com.br

⁴ Graduando em Banco de Dados pela Faculdade Impacta. Email: vitor.fernandes@aluno.faculdadeimpacta.com.br

⁵ Graduando em Banco de Dados pela Faculdade Impacta. Email: gabriel.ezequiel@aluno.faculdadeimpacta.com.br

1. INTRODUÇÃO

O ser humano vem moldando os canídeos a mais de 36 mil anos, gerando diferentes variações e raças para auxiliar os homens [1]. Como reflexo dessas modificações, observou-se uma infinidade de raças caninas com as mais variáveis finalidade como companhia, boiadeiros, caça, guarda entre outras centenas de objetivos.

E todos esses anos de domesticação, levaram a crescente popularidade dos animais de estimação, em especial os cães. Isso têm impulsionado um próspero mercado voltado para pets nas últimas décadas. [2] Estima-se que existem um total de 149,6 milhões de pets no Brasil, sendo 58,1 milhões de cães e 27,1 milhões de gatos. Tendo em vista esse grande número de animais de estimação, o segmento pet mostra crescente evolução e grandes chances de seguir se consolidando como um ramo forte. Seguindo essa mesma tendência, a diversidade de raças caninas disponíveis para compra, aumentou significativamente.

Com esse aumento, a identificação precisa das diferentes raças tornou-se um desafio, para os aspirantes a proprietários. Esta dificuldade de reconhecimento e distinção de raças caninas pode levar a escolhas equivocadas de aquisição, que não consideram as características comportamentais, físicas e de cuidados específicos de cada raça.

A capacidade de identificar com precisão a raça de um cão a partir de imagens pode auxiliar significativamente na promoção de compras responsáveis, alinhando as características do animal com o estilo de vida, expectativas e necessidades dos futuros proprietários. Além disso, essa abordagem pode aprimorar a eficiência dos canis ao informar as carências de cada raça para as famílias interessadas, podendo assim diminuir o número de abandono, devoluções e aumentar o bem-estar animal.

Nesse contexto, o reconhecimento de raças caninas por meio de técnicas avançadas de Visão Computacional pode ser uma ferramenta relevante. Ao permitir a identificação precisa das raças de cães com base em características visuais.

2. CARACTERIZAÇÃO DO PROBLEMA

Com o crescimento de números de pets no país [3] e desse mercado como um todo, surgem oportunidades econômicas substanciais para empresas que atendem às necessidades dos proprietários de animais de estimação.

Tabela 1: Instituto Pet Brasil - População de animais de estimação no Brasil - 2022 -
Em milhões

Ano	Cães	Gatos	Aves	Peixes	Rep. Peq. Mam.	Total
2018	54,2	23,9	39,8	19,1	2,3	139,3
2019	55,1	24,7	40	19,4	2,4	141,6
2020	55,9	25,6	40,4	19,9	2,5	144,31
2021	58,1	27,1	41	20,8	2,5	149,53

Produtos e serviços que vão desde alimentos, acessórios, serviços de saúde, hospedagem, até cuidados com o comportamento animal têm testemunhado um aumento na demanda. Isso cria oportunidades para inovações, como o nosso projeto propõe.

No entanto, o crescimento exponencial do mercado pet também trouxe à tona desafios críticos, especialmente no que diz respeito à seleção responsável de animais de estimação.

Muitos adotantes acabam escolhendo seus pets pelo aspecto físico, porte ou moda, em vez de considerar as necessidades específicas da raça em relação ao seu estilo de vida. E essa análise superficial preliminar pode acabar gerando problemas na convivência do animal com seu dono, as raças podem apresentar beleza, mas precisam de cuidados específicos que raramente são levados em consideração, como por exemplo características comportamentais, físicas e de cuidados particulares de cada raça.

Esta dificuldade de reconhecimento e distinção de raças caninas pode levar a frustrações tanto para o dono quanto para o animal, que pode acabar afetando seu comportamento e causando problemas sérios. Nesse caso, a possibilidade de

devolução do animal vira uma opção, gerando perda no valor investido pelo dono e desapontamento de ambas as partes [4].

Nesse contexto, a capacidade de identificar com precisão a raça de um cão a partir de imagens se destaca como uma solução valiosa. Ao fornecer aos futuros proprietários o nome específico da raça, ajuda a alinhar de forma mais precisa as expectativas dos proprietários com as necessidades do animal. Isso não só pode melhorar a convivência, como também reduzir o número de abandono de animais e devoluções.

3. DESCRIÇÃO DA BASE DE DADOS

A base de dados em questão abrange uma vasta variedade de raças, compreendendo um total de 20 tipos diferentes, englobando tanto aqueles que são considerados mais populares e comuns, quanto os mais "incomuns" e exóticos, totalizando assim 5.317 imagens de cães. Essas imagens foram coletadas de diversas fontes, o que garante uma representação ampla de ambientes, condições de iluminação, ângulos de captura e contextos.

Isso fornece uma riqueza de informações e um conjunto de dados verdadeiramente abrangente para qualquer tipo de análise ou aplicação relacionada a cães. Possui também a seguinte característica: imagens de alta resolução, capturando detalhes cruciais que variam de características visuais a texturas de pelos. Não foi necessária a manipulação de variáveis, pois a base trata-se apenas de imagens.

Sendo assim, analisa-se a imagem diretamente, sem passar por qualquer alteração, conforme os exemplos das figuras 1 e 2. Por fim, essa base encontra-se hospedada no site Kaggle [5].



Figura 1: Raça Pekinese



Figura 2: Raça Bloodhound

4. APLICAÇÃO DAS TÉCNICAS

Neste projeto, TensorFlow [6] e Keras [7] foram empregados para desenvolver um sistema capaz de identificar a raça de um cão em uma imagem. TensorFlow é uma biblioteca de código aberto amplamente utilizada para aprendizado de máquina e aprendizagem profunda, enquanto Keras é uma interface de alto nível que simplifica a construção, treinamento e avaliação de modelos de redes neurais.

Com o auxílio de *Keras*, o conjunto de treinamento foi preparado, que incluiu a adaptação das imagens para um formato prático para redes neurais, além da aplicação de transformações, como giros, *zoom* e inversão horizontal. Essas transformações desempenham um papel fundamental na criação de um conjunto de dados diversificado e coeso, essencial para o treinamento eficaz do modelo.

A parte principal do projeto é a rede neural convolucional, conhecida pela sigla CNN [8], uma poderosa ferramenta para análise de imagens. As CNNs são um tipo de rede neural profunda especialmente projetada para resolver desafios de visão computacional. Essas redes são altamente eficazes no reconhecimento de imagens, segmentação de objetos e detecção de características visuais.

O treinamento é uma fase crítica do projeto. Foi aplicado um conjunto de imagens representando diversas raças de cães para ensinar o modelo a

reconhecê-las. Esse treinamento ocorre em várias etapas, permitindo ao modelo aprender progressivamente mais sobre as raças caninas distintas.

Finalmente, foi demonstrado como utilizar o modelo treinado para identificar a raça de um cão em uma nova imagem. Esse processo envolve a preparação da imagem, a execução da previsão pelo modelo e, por fim, a identificação da raça do cão representado na imagem.

Este projeto exemplifica de forma prática como é possível desenvolver um sistema de reconhecimento de imagens utilizando técnicas de aprendizado profundo. Desde a organização dos dados até o treinamento e avaliação do modelo, cada etapa desempenha um papel fundamental na construção de um sistema preciso e confiável. Em muitos casos, é necessário ajustar e aprimorar o sistema para otimizá-lo para aplicações do mundo real. As técnicas empregadas neste projeto podem ser aplicadas a uma variedade de problemas de reconhecimento de imagens.

5. RESULTADOS

Os resultados foram obtidos a partir de uma extensa coleção de 5.317 imagens, que abrange 20 raças específicas de cães. Essas imagens foram divididas em 70% para o conjunto de treinamento, totalizando 3.717 imagens, enquanto 15% foram destinados aos conjuntos de teste e 15% para validação, contando 800 imagens para cada um desses conjuntos.

Os resultados evidenciaram um desempenho superior para o modelo em consideração. A Figura 3 mostra uma representação visual das taxas de acurácia observadas ao longo de 100 épocas, revelando um aprendizado superior. O modelo alcançou uma acurácia de 82% na última época, destacando um desempenho excepcional na distinção das raças de cães presentes no conjunto de dados.

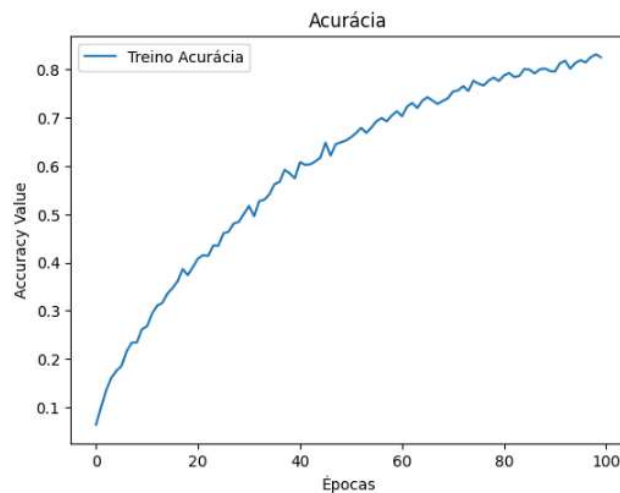


Figura 3: Gráfico Acurácia

Na análise de reconhecimento de imagem, várias métricas são utilizadas para avaliar o desempenho dos modelos. Além da métrica de acurácia, são calculados e considerados os valores de precisão, recall e F1-Score com os seguintes resultados demonstrados na Tabela 2:

Tabela 2: Resultados da avaliação de desempenho do modelo

Métrica de Avaliação	Porcentagem
Acurácia	78%
Precisão	65%
Recall	70%
F1-Score	73%

Essas análises são essenciais para fornecer uma compreensão mais abrangente sobre a eficácia do modelo na identificação de imagens. Cada uma dessas análises oferece uma perspectiva única: A precisão mede a proporção de identificações corretas, o recall indica a proporção de imagens corretamente identificadas em relação ao total de imagens corretas, enquanto o F1-Score é uma média combinada de precisão e recall. Essas ideias são fundamentais para aprimorar algoritmos de reconhecimento de imagem.

Foram coletadas 10 imagens aleatórias no site *Google* para cada uma das 20 raças distintas para avaliar o desempenho do modelo. Os resultados desses testes estão resumidos na Tabela 3.

Tabela 3: Porcentagem de acerto do modelo para cada raça

Raças	Porcentagem de Acerto
Basset	80%
Beagle	70%
Blenheim Spaniel	80%
Bloodhound	90%
Bluetick	80%
Borzoi	80%
Chihuahua	80%
Coonhound	90%
English Foxhound	80%
Galgo Afegão	90%
Japanese Spaniel	80%
Lebrel Irlandes	90%
Maltese Dog	80%
Papillon	70%
Pekinese	80%
Redbone Coonhound	80%
Rhodesian Ridgeback	90%
Shih-Tzu	90%
Toy Terrier	80%
Walker Coonhound	80%

6. CONSIDERAÇÕES FINAIS

Esses resultados estabelecem uma base sólida para futuras investigações, buscando aprimorar ainda mais a capacidade de reconhecimento de raças de cães por meio de técnicas avançadas de aprendizado de máquina. Como uma extensão deste trabalho, é vislumbrada a expansão para um conjunto de dados abrangendo 120 raças distintas com mais de 20.500 imagens. Esta representa uma ampliação de

um desafio adicional e promissor para o modelo, mudando novos horizontes na identificação precisa e robusta de uma gama ainda mais diversificada de raças caninas.

Além disso, são vislumbradas várias aplicações práticas para esses modelos de reconhecimento de raças caninas:

- Plataformas de Adoção de Animais: Uma das aplicações mais diretas e impactantes é a integração desses modelos em plataformas de adoção de animais e petshops. Ao facilitar a identificação precisa das raças de cães disponíveis para adoção por meio de fotos, esses modelos auxiliam potenciais adotantes a encontrar o animal ideal para eles. Isso não apenas aumenta as chances de uma adoção responsável, mas também cria uma conexão mais rápida entre o animal e o novo lar.
- Pesquisa e Estatísticas: Além disso, os modelos de reconhecimento de raças caninas podem ser usados na coleta de dados sobre raças de cães com base em imagens enviadas. Essa coleta de informações pode ser valiosa para a pesquisa, permitindo uma compreensão mais profunda das preferências populacionais. Essas visões são cruciais para estudos sobre comportamento animal, demanda por raças específicas e até mesmo para direcionar políticas públicas relacionadas ao bem-estar animal.
- Aplicações educacionais: outra vertente promissora é a criação de ferramentas interativas para educação sobre raças de cães. Essas ferramentas permitem que os usuários identifiquem visualmente diferentes raças, tornando-se uma ótima maneira de educar e conscientizar sobre a diversidade de animais de estimação. Esses recursos são implementados em escolas, centros de treinamento de animais ou até mesmo disponibilizados ao público, ajudando a promover uma compreensão mais ampla e precisa das várias raças caninas.

Apesar dos desafios encontrados, este estudo fornece insights valiosos, incentivando futuras investigações para melhorar a capacidade de redes neurais em reconhecimento de imagens em conjuntos de dados extremamente heterogêneos.

7. REFERÊNCIAS BIBLIOGRÁFICAS

1. Universidade de São Paulo. Livros Abertos. "Canis Lupus Familiaris: Uma abordagem evolutiva e veterinária". Disponível em: <https://www.livrosabertos.sibi.usp.br/portaldelivrosUSP/catalog/view/326/287/1212>.
2. Serviço Brasileiro de Apoio às Micro e Pequenas Empresas (SEBRAE). "Crescimento do Mercado Pet e Oportunidade de Negócio". Disponível em: <https://sebrae.com.br/sites/PortalSebrae/ufs/al/artigos/crescimento-do-mercado-pet-e-oportunidade-de-negocio,021731b7fe057810VgnVCM1000001b00320aRCRD>.
3. Ministério da Agricultura, Pecuária e Abastecimento (MAPA). "População de Animais de Estimação no Brasil - Resultados de 2018". Disponível em: https://www.gov.br/agricultura/pt-br/assuntos/camaras-setoriais-tematicas/documentos/camaras-setoriais/animais-e-estimacao/2019/26deg-ro-1/14-10-ipb_mercado_pet_resultados_2018_draft2.pdf.
4. Universidade de São Paulo. Jornal da USP. "Modismo com Raças de Cachorro Gera Abandono de Animais e Inconveniências às Famílias". Disponível em: <https://jornal.usp.br/atualidades/modismo-com-racas-de-cachorro-gera-abandono-de-animais-e-inconveniencias-as-familias/>.
5. Kaggle. "Stanford Dogs Dataset". Disponível em: <https://www.kaggle.com/datasets/jessicali9530/stanford-dogs-dataset>.
6. TensorFlow. "TensorFlow - An Open Source Machine Learning Framework". Disponível em: <https://www.tensorflow.org>.
7. Keras. "Keras - The Python Deep Learning API". Disponível em: <https://keras.io/guides/>.
8. IBM. "Convolutional Neural Networks - Topic Overview". Disponível em: <https://www.ibm.com/topics/convolutional-neural-networks>.